

Pitch MiniRed — 10 minutos, dos presentadores

Cada página corresponde a una diapositiva de **MiniRed_Pitch.pptx**. Arriba, la lámina tal como se ve proyectada; abajo, qué se dice sobre ella.

A lleva la voz del negocio: abre, plantea el problema, el impacto y el cierre. **B** lleva la voz técnica: el modelo, las reglas, la validación y la demo. Así ninguno habla más de dos minutos seguidos.

Lo escrito es para ensayar, no para leer. Una vez tomada la idea, contarla con palabras propias suena mucho mejor.

Antes de empezar

- ☐ El portal **abierto en otra ventana**, ya filtrado en "Todas las zonas"
- ☐ SQL Server levantado, por si piden ver una consulta
- ☐ La presentación en modo presentador, para leer las notas de cada lámina
- ☐ Alguien cronometrando: a los 8 minutos hay que estar en la demo
- ☐ Acordar quién dice cada nombre en la presentación inicial

TRABAJO PRÁCTICO · UNIDAD 3

**Minería de Datos,
KDD y Modelado
Dimensional****Integrantes**

Santiago Skrobicki

Nombre del compañero

Caso: MiniRed S.A.

6 sucursales · 2024 – 2025

**Dónde nos quedamos sin stock,
y dónde tenemos plata
dormida**

El trabajo plantea el caso de una cadena de minimercados y pide resolver un desafío de abastecimiento sobre su data warehouse.

Perspectiva elegida: Opción B · Logística e Inventario

Buenas tardes. Somos [nombre] y [nombre], y venimos a presentar el trabajo práctico de la Unidad 3.

El caso es MiniRed, una cadena de seis minimercados con un depósito central. El enunciado nos pide ponernos en el lugar de una consultora y resolver un desafío de abastecimiento sobre dos años de datos.

Elegimos la perspectiva de logística e inventario, así que la pregunta que tratamos de responder fue: **dónde está perdiendo plata MiniRed con el stock.**

En los próximos diez minutos les contamos qué encontramos, cómo nos aseguramos de que fuera cierto, y a qué decisiones lleva.

Pasa a: "Arranquemos por el problema, que tiene dos caras."

EL ENCARGO

Dos formas de perder plata con el stock

Las dos son problemas de abastecimiento, y son opuestas: corregir una mal empeora la otra.



Góndola vacía

El cliente va a buscar el producto y no lo encuentra. Es venta perdida, y además manda al cliente al competidor de la esquina.

5,22 %

de los días-producto
sin stock en góndola



Depósito lleno

Mercadería que nadie compró. Es capital inmovilizado, ocupa lugar y puede vencerse. Nunca falta nada porque sobra todo.

\$ 12,0 M

en góndola al cierre
del período analizado

Fuente: MiniRed_DW - 131.580 observaciones diarias de góndola sobre 731 días

Cuando uno piensa en un problema de stock, piensa en la góndola vacía. El cliente va a buscar el producto, no lo encuentra, y se va. Eso es venta perdida, y encima se lleva al cliente al competidor de la esquina.

Es el primero de los dos problemas que fuimos a buscar.

En MiniRed eso pasa el **5,22%** de las veces. De cada cien días que un producto estuvo a la venta, en cinco no estaba.

Pero hay un segundo problema, que es el opuesto y casi nadie lo mira: el depósito lleno. Mercadería que nadie compró. Son **doce millones de pesos** parados en góndola, que además ocupan lugar y pueden vencerse.

Y acá está lo importante: **corregir mal uno empeora el otro**. Si la respuesta a los faltantes es "mandemos más mercadería", se termina con el segundo problema. Por eso hay que mirar los dos juntos.

Pasa a: "Para poder mirarlos, primero hubo que construir de dónde mirarlos."

PUNTO DE PARTIDA

La cátedra da el diseño; la base la construimos nosotros

Generamos MiniRed_DW con comportamientos realistas puestos a propósito y documentados. Los datos son simulados; las cuentas que siguen son reales.

315.969

líneas de ticket

Fact_Ventas

153.510

fotos diarias de góndola

Fact_Stock

731

días consecutivos

2024 – 2025

30

productos × 6 sucursales

5 categorías

¿Por qué plantar patrones a propósito?

Un dataset generado al azar no contiene ninguna regla que descubrir: sería buscar huellas en una playa donde nadie caminó. La contrapartida —que la validación estadística no alcanza y todo hallazgo debe contrastarse contra la lógica del negocio— es exactamente el punto 5 de la consigna.

Un detalle de método, porque seguramente lo van a preguntar: la cátedra define el diseño del caso, pero no entrega la base cargada. La construimos nosotros.

Son dos años completos: **315.969 líneas de ticket** y **153.510 fotos diarias de góndola**, sobre treinta productos en seis sucursales.

Los datos son simulados, y lo decimos de entrada. Le pusimos comportamientos realistas a propósito, y están documentados en el script.

¿Por qué a propósito? Porque un conjunto de datos generado al azar no tiene ninguna regla adentro: sería buscar huellas en una playa donde nadie caminó.


Ahora bien, eso mismo nos obliga a ser más rigurosos con la validación. Y ese rigor es justamente uno de los puntos teóricos que vamos a mostrar.

Pasa a: "Te paso la palabra para el modelo." → B

MODELADO DIMENSIONAL

Dos procesos de negocio, tres dimensiones compartidas

Vender y reponer son procesos distintos, con distinto grano. Comparten Tiempo, Sucursal y Producto: eso convierte dos estrellas en una constelación.



Vender y reponer parecen lo mismo, pero son dos procesos distintos.

Una venta es un evento: pasó a las tres de la tarde. El stock es una foto: al cierre del día había tantas unidades. Tienen distinto **grano**, así que van en dos tablas de hechos separadas.

Lo que las une son tres dimensiones que comparten: tiempo, sucursal y producto. A eso se le llama **dimensiones conformadas**, y son las que permiten preguntar "cuánto vendimos contra cuánto ingresamos" en una sola consulta.

Dos estrellas unidas por dimensiones compartidas es una **constelación**.

Y fíjense en la asimetría: cajero y medio de pago están sólo del lado de las ventas. El ingreso de mercadería no pasa por caja. Esa asimetría es la prueba de que el stock es un proceso separado, y no una columna más en la tabla de ventas.

Pasa a: "Hay una medida en este modelo que decide si todo funciona o no."

EL ERROR QUE EVITAMOS

Diez botellas el lunes y diez el martes no son veinte

Son las mismas diez, fotografiadas dos veces. El stock se suma por sucursal y por producto, nunca por tiempo: es una medida semi-aditiva.

Sumando los 731 días

6.159.125

unidades — no significa nada

Stock real en góndola

8.161

unidades — la lectura correcta

Tres órdenes de magnitud de diferencia. En el cubo se resuelve configurando la medida con LastNonEmpty; el asistente la deja en Sum por defecto.

Pausa acá. Es el número que se recuerda.

Esta es la lámina más importante del trabajo.

Si hay diez botellas el lunes y diez el martes, **no hay veinte botellas**. Son las mismas diez, fotografiadas dos veces.

Las unidades vendidas sí se suman: vendiste diez y diez, vendiste veinte. Pero el stock no se suma en el tiempo. A eso se le dice **medida semi-aditiva**: se suma por sucursal y por producto, nunca por fecha.

¿Cuánto importa esto? Si uno suma mal los 731 días, le da **seis millones ciento cincuenta y nueve mil** unidades. El stock real en góndola es **ocho mil ciento sesenta y uno**.

Tres órdenes de magnitud. Y el asistente de Analysis Services, si uno le da "siguiente" cuatro veces, lo deja mal por defecto. Hay que ir a la propiedad y cambiarla a mano.

Pasa a: "Te devuelvo para la parte conceptual." → **A**

CONCEPTO Y DISCIPLINAS

De responder preguntas a descubrir patrones

Una consulta OLAP contesta lo que ya sabíamos preguntar. La minería de datos encuentra lo que no sabíamos que había que preguntar.

Consulta analítica (OLAP)

¿Cuánto quebró la zona Oeste en mayo? — La pregunta ya trae la hipótesis adentro.

Minería de datos

El quiebre de bebidas en el Oeste no cae el fin de semana: cae el martes. Nadie lo había preguntado.

Tres disciplinas, una solución**1 Gestión de bases de datos**

Modelo dimensional en SQL Server, cubo en Analysis Services

2 Estadística inferencial

Soporte, confianza, lift y validación con datos que el modelo no vio

3 Inteligencia artificial

Asistentes usados para diseñar consultas, cuestionar hallazgos y maquetar el portal

Una aclaración conceptual, porque es fácil confundir las dos cosas.

Una consulta analítica responde lo que ya sabíamos preguntar: "¿cuánto quebró la zona Oeste en mayo?". La pregunta ya trae la hipótesis adentro.

La minería de datos es otra cosa: es encontrar lo que **no sabíamos que había que preguntar**. Por ejemplo, que el faltante de bebidas en el Oeste no cae el fin de semana. Cae el martes. Nadie lo hubiera preguntado así.

Y para llegar a eso hicieron falta tres disciplinas: la gestión de bases de datos para el modelo y el cubo, la estadística para medir si el patrón es real, y la inteligencia artificial, que usamos para diseñar consultas, para que nos cuestionara los hallazgos y para maquetar el portal.

TIPOS DE VARIABLES

Qué se puede promediar y qué sólo se puede contar

La clasificación no es un trámite: define qué operación tiene sentido sobre cada columna.

Continuas

Admiten cualquier valor de un rango. Se promedian.

- ImporteTotal — pesos facturados
- CostoUnitario — costo por unidad
- ValorInventario — capital en góndola

Discretas numéricas

Conteos. No existen los valores intermedios.

- Cantidad — unidades vendidas
- StockDisponible — unidades en góndola
- CantidadIngresada — unidades repuestas

Discretas categóricas

Etiquetas. Sirven para agrupar y filtrar.

- Zona, Categoría, Proveedor
- EsFinDeSemana — binaria
- EsQuiebre — la variable objetivo

La variable objetivo del análisis es EsQuiebre: binaria, y por eso el modelo se evalúa con confianza y lift, no con un error promedio.

Rápido, porque es más técnico que interesante, pero define qué operación tiene sentido sobre cada columna.

Las **continuas** admiten cualquier valor y se promedian: importes, costos.

Las **discretas numéricas** son conteos: unidades vendidas, unidades en góndola. No existe media unidad.

Y las **categóricas** son etiquetas para agrupar: zona, categoría, proveedor.

Nuestra variable objetivo es una categórica binaria: hubo quiebre o no hubo. Y por eso el análisis se evalúa con confianza y lift, y no con un error promedio.

PROCESO KDD

Las cinco fases, aplicadas a este caso

1

Selección

Recorte del modelo a las 7 tablas de la perspectiva logística. Se descartan cajero, medio de pago y promociones.

2

Preprocesamiento

Controles de integridad: sin stock negativo, sin huérfanos. Las dos tablas de hechos cierran en 1.372.990 unidades.

3

Transformación

Cálculo de tasa de quiebre, días de cobertura y valor de inventario. Banderas convertidas a enteros para poder sumarlas.

4

Minería de datos

Extracción de reglas SI/ENTONCES sobre 131.580 observaciones, con soporte, confianza y lift.

5

Interpretación

Validación con hold-out temporal y control de correlaciones espurias. Traducción a acciones de abastecimiento.

Punto 3 de la consigna. Cada fase dejó su rastro en el repositorio: scripts, controles y resultados reproducibles.

Las cinco fases del proceso, en una lámina.

Selección: recortamos el modelo a las siete tablas de la perspectiva logística. Descartamos cajero, medio de pago y promociones, que son de otra perspectiva.

Preprocesamiento: controles de integridad. Las dos tablas de hechos cierran exactamente en 1.372.990 unidades, así que el cruce entre ambas es real.

Transformación: calculamos tasa de quiebre, días de cobertura y valor de inventario.

Minería: extracción de reglas sobre 131.580 observaciones.

Interpretación: validación y traducción a acciones concretas.

Las dos últimas son las que tienen contenido propio, así que ahí nos detenemos.

Pasa a: "Contales qué encontramos." → B

APRENDIZAJE INDUCTIVO

Cuatro reglas inducidas desde los casos particulares

Cada fila del almacén es una observación. De ellas se infieren reglas generales, y cada una tiene una acción asociada.

R1	SI Bebidas en zona Oeste	19,34 % confianza	1,91x lift	→ Reforzar la reposición antes del fin de semana
R2	SI Proveedor Arcor, ciclo de 14 días	9,69 % confianza	2,60x lift	→ Renegociar frecuencia o subir el nivel objetivo
R3	SI Congelados en verano	27,03 % confianza	3,97x lift	→ Nivel objetivo estacional de diciembre a febrero
R4	SI Sobrestock en San Justo	49,95 % confianza	1,62x lift	→ Recalibrar el nivel objetivo a su demanda real

El lift indica cuántas veces más probable es el quiebre cuando se cumple la condición. Un lift de 1 sería ruido.

Cuatro reglas, y cada una tiene una acción asociada. Les cuento dos.

R1: en zona Oeste, las bebidas quiebran el 19% de los días. Casi el doble de lo normal. La causa es que ahí se vende mucho más los fines de semana, pero la reposición se calcula sobre un día común.

R3: los congelados en verano quiebran el 27% de los días. Casi **cuatro veces** más probable que en el resto del año. Mismo problema: el pedido es el mismo todo el año.

Ese número de la derecha es el **lift**: cuántas veces más probable es el quiebre cuando se cumple la condición. Si diera uno, la regla no diría nada.


Las otras dos: Arcor entrega cada catorce días en vez de siete, y San Justo tiene el problema inverso, sobrestock.

Pasa a: "Ahora, encontrar un patrón es fácil. Lo difícil es demostrar que es real."

VALIDACIÓN

Descubiertas en 2024, verificadas contra 2025

Si una regla fuera casualidad de los datos con los que se encontró, al cambiar de año se caería. Ninguna se movió más de 1,3 puntos.



Por qué importa

Con suficientes cruces siempre aparece alguna coincidencia llamativa. La prueba de que un patrón es real no es que se vea bien en el gráfico: es que sobreviva a datos que el análisis no miró.

< 1,3 pts

de desvío máximo entre el año de inducción y el de prueba

Con suficientes cruces, siempre aparece alguna coincidencia llamativa. Así que hicimos esto:

Buscamos las reglas mirando **solamente 2024**. Y después las probamos contra **2025**, que es un año que el análisis no había visto.

Si una regla fuera casualidad de esos datos puntuales, al cambiar de año se caería. Ninguna se movió más de **1,3 puntos**.


La prueba de que un patrón es real no es que se vea lindo en el gráfico. Es que sobreviva a datos que no miraste cuando lo encontraste.

Pasa a: "Y hay un segundo control, que es el que más nos gustó."

CORRELACIÓN ESPURIA

¿Es el proveedor, o es la zona?

Coca-Cola encabeza el ranking de faltantes. Al excluir la zona Oeste del cálculo, el efecto desaparece. Con Arcor pasa lo contrario.



Efecto que se desvanece

10,8 % → 0,8 %

Nunca fue Coca-Cola. Era la zona.

Efecto que se refuerza

9,7 % → 11,5 %

Acá sí hay un problema real de ciclo de entrega.

Presentar sólo la primera serie llevaría a renegociar el contrato equivocado.

La lámina más fuerte. No apurarla.

Miren el ranking de proveedores por faltantes. Arriba de todo está Coca-Cola, con 10,8%. La conclusión obvia sería: hay un problema con Coca-Cola.

Pero hicimos una cosa más. Sacamos la zona Oeste del cálculo y volvimos a medir.

Coca-Cola cae a **0,8%**. El efecto **desaparece**. Nunca fue Coca-Cola: era la zona. La gaseosa simplemente se vende muchísimo ahí los fines de semana, y arrastraba el promedio del proveedor.

Con Arcor pasa exactamente lo contrario: sube de 9,7 a **11,5%**. El efecto se **refuerza**. Ahí sí hay un problema real, y es el ciclo de catorce días.

Si hubiéramos presentado sólo la primera columna, MiniRed habría ido a renegociar el contrato equivocado.

Pasa a: "¿Cuánto vale todo esto en pesos?" → A

IMPACTO

Qué cuesta hoy, y qué se libera al corregirlo

\$ 75,5 M

Venta perdida estimada en 12 meses

Asume un día de demanda perdida por cada día-producto en quiebre

\$ 960 K

Capital liberable en San Justo

Si operara con los 4 días de cobertura del resto de la cadena

2.969

Días de faltante de bebidas en el Oeste

Concentrados en los días hábiles posteriores al fin de semana

Tres decisiones concretas

- Nivel objetivo diferenciado para fin de semana en las bebidas del Oeste
- Renegociar con Arcor el ciclo de 14 días, o compensarlo subiendo el nivel objetivo
- Recalibrar San Justo a su demanda real y redistribuir el excedente

Tres números y tres decisiones.

La venta perdida por faltantes, en doce meses, la estimamos en **75 millones de pesos**. Asumiendo un día de demanda perdida por cada día de góndola vacía.

En San Justo hay cerca de **un millón** que se podría liberar, simplemente calibrando su reposición a lo que realmente vende: hoy tiene diez días de cobertura contra cuatro del resto de la cadena.

Y las tres acciones: nivel objetivo diferenciado para el fin de semana en las bebidas del Oeste; renegociar el ciclo con Arcor o compensarlo; y recalibrar San Justo.

Pasa a: "Y esto no queda en un informe. Mostrales." → B

DEMOSTRACIÓN EN VIVO

El portal de abastecimiento

Los hallazgos anteriores no quedan en un informe: el gerente los explora solo, sin saber SQL.

1

Estado general

Cuatro indicadores con semáforo y las tres alertas más urgentes del momento

2

Filtrar por Oeste y Bebidas

Todo se recalcula: la tasa salta a 19,34 %, el mismo número que dio SQL.

3

Quiebre por día

El pico cae el martes, no el fin de semana. El efecto de arrastre, visible.

4

Control de proveedores

Coca-Cola se desploma al excluir el Oeste; Arcor se mantiene arriba.

Cómo está hecho

- Sin librerías ni compilación
- Gráficos dibujados a mano en SVG
- SQL Server resume 470.000 registros a 783 filas
- Los filtros reagregan por conteos, no por promedios de tasas
- Preparado para enchufarle el backend

santiagokrobacki.github.io

Cambiar a la ventana del portal. Cuatro movimientos, sin improvisar.

Volver a la presentación.

Esto es lo que ve el gerente de abastecimiento.

(1) Arriba, el estado general: cuatro indicadores con semáforo, y las tres alertas más urgentes. Cada alerta nombra el lugar concreto donde hay que actuar.

(2) Filtro por zona Oeste y categoría Bebidas. (*hacerlo*) Miren: la tasa salta a **19,34%**. Ese es exactamente el mismo número que calculó SQL Server sobre los 470.000 registros originales. El navegador reagrega sumando conteos, no promediando porcentajes.

(3) Este gráfico es el del efecto de arrastre: el pico no cae el fin de semana, cae el martes. El finde vacía la góndola y el hueco aparece después.

(4) Y acá abajo, el control de proveedores que les mostrábamos recién, pero navegable.

Pasa a: "Cerrar vos." → A

CONCLUSIÓN

El problema no era reponer más: era reponer con el parámetro correcto

MiniRed calcula su nivel objetivo de reposición sobre el promedio de días hábiles. Los tres patrones de quiebre y el de sobrestock salen todos de ese mismo supuesto.

4

reglas validadas
con hold-out temporal

3

acciones concretas
sobre el nivel objetivo

1

correlación espuria
descartada a tiempo

Portal, código y documentación: github.com/SantiagoSkrobacki/TP_MiniRedBaseDeDatos · Gracias.

Para cerrar, una sola idea.

Salimos a buscar dónde MiniRed se quedaba sin stock. Y lo que encontramos es que el problema no era reponer poco: era **reponer con el parámetro equivocado**.

MiniRed calcula cuánto reponer usando el promedio de los días hábiles. Los tres patrones de faltante y el de sobrestock salen todos de ese mismo supuesto.

Cuatro reglas validadas, tres acciones concretas, y una correlación espuria que descartamos a tiempo.

Con eso cerramos. Quedamos para las preguntas que quieran hacernos.

Preguntas que pueden caer

"¿Los datos son reales?" — La base es simulada y está declarado. Pero los números no están inventados: son el resultado de consultas reales sobre esa base. La prueba está en la demo — el 19,34% del portal y el de SQL Server coinciden.

"¿Por qué no usaron el motor de minería de datos de Analysis Services?" — Está discontinuado desde SQL Server 2022. El descubrimiento lo hicimos en la capa analítica, con validación estadística explícita, que es lo que pide la consigna.

"¿Y si el patrón fuera casualidad?" — Para eso está el hold-out: las cuatro reglas se sostienen en un año que el análisis no miró. Y el control de correlación espuria descartó tres proveedores que parecían culpables.

"¿Por qué San Justo aparece en rojo si tiene cero faltantes?" — Porque tiene el problema opuesto. Diez días de cobertura contra cuatro del resto: nunca le falta nada porque le sobra todo. Es capital inmovilizado.

"¿Cuánto tardaron en armar la base?" — La generación es un script reproducible: dos ejecuciones dan exactamente los mismos números, porque el ruido se calcula de forma determinística sobre las claves.

Si preguntan algo que no saben: decirlo sin rodeos y ofrecer mostrarlo en los datos. Es mucho mejor que improvisar: el repositorio está publicado y las consultas son reproducibles, así que siempre se puede verificar en el momento.