

Minería de Datos, KDD y Modelado Dimensional

Integrantes

Santiago Skrobacki

Nombre del compañero

Caso: MiniRed S.A.

6 sucursales · 2024 – 2025

Dónde nos quedamos sin stock, y dónde tenemos plata dormida

El trabajo plantea el caso de una cadena de minimercados y pide resolver un desafío de abastecimiento sobre su data warehouse.

Perspectiva elegida: Opción B · Logística e Inventario

Dos formas de perder plata con el stock

Las dos son problemas de abastecimiento, y son opuestas: corregir una mal empeora la otra.



Góndola vacía

El cliente va a buscar el producto y no lo encuentra. Es venta perdida, y además manda al cliente al competidor de la esquina.

5,22 %

de los días-producto
sin stock en góndola



Depósito lleno

Mercadería que nadie compró. Es capital inmovilizado, ocupa lugar y puede vencerse. Nunca falta nada porque sobra todo.

\$ 12,0 M

en góndola al cierre
del período analizado

La cátedra da el diseño; la base la construimos nosotros

Generamos MiniRed_DW con comportamientos realistas puestos a propósito y documentados. Los datos son simulados; las cuentas que siguen son reales.

315.969

líneas de ticket

Fact_Ventas

153.510

fotos diarias de góndola

Fact_Stock

731

días consecutivos

2024 – 2025

30

productos × 6 sucursales

5 categorías

¿Por qué plantar patrones a propósito?

Un dataset generado al azar no contiene ninguna regla que descubrir: sería buscar huellas en una playa donde nadie caminó. La contrapartida —que la validación estadística no alcanza y todo hallazgo debe contrastarse contra la lógica del negocio— es exactamente el punto 5 de la consigna.

Dos procesos de negocio, tres dimensiones compartidas

Vender y reponer son procesos distintos, con distinto grano. Comparten Tiempo, Sucursal y Producto: eso convierte dos estrellas en una constelación.



Dim_Cajero y Dim_MedioPago quedan sólo del lado de las ventas: el ingreso de mercadería no pasa por caja. Esa asimetría es la prueba de que el stock es un proceso separado y no una columna más en Fact_Ventas.

Diez botellas el lunes y diez el martes no son veinte

Son las mismas diez, fotografiadas dos veces. El stock se suma por sucursal y por producto, nunca por tiempo: es una medida semi-aditiva.

Sumando los 731 días

6.159.125

unidades — no significa nada

Stock real en góndola

8.161

unidades — la lectura correcta

Tres órdenes de magnitud de diferencia. En el cubo se resuelve configurando la medida con LastNonEmpty; el asistente la deja en Sum por defecto.

De responder preguntas a descubrir patrones

Una consulta OLAP contesta lo que ya sabíamos preguntar. La minería de datos encuentra lo que no sabíamos que había que preguntar.

Consulta analítica (OLAP)

¿Cuánto quebró la zona Oeste en mayo? — La pregunta ya trae la hipótesis adentro.

Minería de datos

El quiebre de bebidas en el Oeste no cae el fin de semana: cae el martes. Nadie lo había preguntado.

Tres disciplinas, una solución

1

Gestión de bases de datos

Modelo dimensional en SQL Server, cubo en Analysis Services

2

Estadística inferencial

Soporte, confianza, lift y validación con datos que el modelo no vio

3

Inteligencia artificial

Asistentes usados para diseñar consultas, cuestionar hallazgos y maquetar el portal

Qué se puede promediar y qué sólo se puede contar

La clasificación no es un trámite: define qué operación tiene sentido sobre cada columna.

Continuas

Admiten cualquier valor de un rango. Se promedian.

- ImporteTotal — pesos facturados
- CostoUnitario — costo por unidad
- ValorInventario — capital en góndola

Discretas numéricas

Conteos. No existen los valores intermedios.

- Cantidad — unidades vendidas
- StockDisponible — unidades en góndola
- CantidadIngresada — unidades repuestas

Discretas categóricas

Etiquetas. Sirven para agrupar y filtrar.

- Zona, Categoría, Proveedor
- EsFinDeSemana — binaria
- EsQuiebre — la variable objetivo

Las cinco fases, aplicadas a este caso

1

Selección

Recorte del modelo a las 7 tablas de la perspectiva logística. Se descartan cajero, medio de pago y promociones.

2

Preprocesamiento

Controles de integridad: sin stock negativo, sin huérfanos. Las dos tablas de hechos cierran en 1.372.990 unidades.

3

Transformación

Cálculo de tasa de quiebre, días de cobertura y valor de inventario. Banderas convertidas a enteros para poder sumarlas.

4

Minería de datos

Extracción de reglas SI/ENTONCES sobre 131.580 observaciones, con soporte, confianza y lift.

5

Interpretación

Validación con hold-out temporal y control de correlaciones espurias. Traducción a acciones de abastecimiento.

Cuatro reglas inducidas desde los casos particulares

Cada fila del almacén es una observación. De ellas se infieren reglas generales, y cada una tiene una acción asociada.

R1**SI Bebidas en zona Oeste****19,34 %** confianza**1,91x** lift

→ Reforzar la reposición antes del fin de semana

R2**SI Proveedor Arcor, ciclo de 14 días****9,69 %** confianza**2,60x** lift

→ Renegociar frecuencia o subir el nivel objetivo

R3**SI Congelados en verano****27,03 %** confianza**3,97x** lift


→ Nivel objetivo estacional de diciembre a febrero

R4**SI Sobrestock en San Justo****49,95 %** confianza**1,62x** lift

→ Recalibrar el nivel objetivo a su demanda real

Descubiertas en 2024, verificadas contra 2025

Si una regla fuera casualidad de los datos con los que se encontró, al cambiar de año se caería. Ninguna se movió más de 1,3 puntos.



Por qué importa


Con suficientes cruces siempre aparece alguna coincidencia llamativa. La prueba de que un patrón es real no es que se vea bien en el gráfico: es que sobreviva a datos que el análisis no miró.

< 1,3 pts

de desvío máximo entre
el año de inducción y el de prueba

¿Es el proveedor, o es la zona?

Coca-Cola encabeza el ranking de faltantes. Al excluir la zona Oeste del cálculo, el efecto desaparece. Con Arcor pasa lo contrario.



Efecto que se desvanece

10,8 % → 0,8 %

Nunca fue Coca-Cola. Era la zona.

Efecto que se refuerza

9,7 % → 11,5 %

Acá sí hay un problema real de ciclo de entrega.

Qué cuesta hoy, y qué se libera al corregirlo

\$ 75,5 M

Venta perdida estimada en 12 meses

Asume un día de demanda perdida por cada día-producto en quiebre

\$ 960 K

Capital liberable en San Justo

Si operara con los 4 días de cobertura del resto de la cadena

2.969

Días de faltante de bebidas en el Oeste

Concentrados en los días hábiles posteriores al fin de semana

Tres decisiones concretas

- Nivel objetivo diferenciado para fin de semana en las bebidas del Oeste
- Renegociar con Arcor el ciclo de 14 días, o compensarlo subiendo el nivel objetivo
- Recalibrar San Justo a su demanda real y redistribuir el excedente

El portal de abastecimiento

Los hallazgos anteriores no quedan en un informe: el gerente los explora solo, sin saber SQL.

1

Estado general

Cuatro indicadores con semáforo y las tres alertas más urgentes del momento

2

Filtrar por Oeste y Bebidas

Todo se recalcula: la tasa salta a 19,34 %, el mismo número que dio SQL

3

Quiebre por día

El pico cae el martes, no el fin de semana. El efecto de arrastre, visible

4

Control de proveedores

Coca-Cola se desploma al excluir el Oeste; Arcor se mantiene arriba

Cómo está hecho

- Sin librerías ni compilación
- Gráficos dibujados a mano en SVG
- SQL Server resume 470.000 registros a 783 filas
- Los filtros reagregan por conteos, no por promedios de tasas
- Preparado para enchufarle el backend

santiagoskrobacki.github.io

CONCLUSIÓN

El problema no era reponer más: era reponer con el parámetro correcto

MiniRed calcula su nivel objetivo de reposición sobre el promedio de días hábiles. Los tres patrones de quiebre y el de sobrestock salen todos de ese mismo supuesto.

4

reglas validadas
con hold-out temporal

3

acciones concretas
sobre el nivel objetivo

1

correlación espuria
descartada a tiempo